

经济与商务实证研究方法

第二讲

陈志远

人大商学院硕博课程
版本：2025 年春季学期

目录

1 线性回归	1
1.1 线性回归与 CEF	1
1.2 线性回归模型的基本性质	3
1.3 线性回归的统计推断	4
1.4 线性回归的因果含义	6

1 线性回归

1.1 线性回归与 CEF

- 随机变量 Y_i 关于 X_i 的线性回归方程为：

$$Y_i = \mathbf{X}_i' \mathbf{b} + e_i \quad (1)$$

- 线性回归的估计系数来自于求解如下最小化问题

$$\beta = \underset{\mathbf{b}}{\operatorname{argmin}} E[(Y_i - \mathbf{X}_i' \mathbf{b})^2] \quad (2)$$

$\beta = (\beta_1, \dots, \beta_k)'$, $\mathbf{b} = (b_1, \dots, b_k)'$, $b \in \mathbb{R}^k$, $\mathbf{X}_i' = (X_{i1}, X_{i2}, \dots, X_{ik})$, 即 $\mathbf{X}_i' \mathbf{b} = \sum_{j=1}^k X_{ij} \cdot b_j$.

- 求解 $\min_b E[(Y_i - \mathbf{X}_i' b)^2]$ 的一阶条件:

$$\begin{aligned}
 2E[\mathbf{X}_i(Y_i - \mathbf{X}_i' \beta)] &= 0 \Leftrightarrow E[\mathbf{X}_i(Y_i - \mathbf{X}_i' \beta)] = \mathbf{0} \\
 &\Rightarrow E(\mathbf{X}_i Y_i) = E(\mathbf{X}_i \mathbf{X}_i') \cdot \beta \\
 &\Rightarrow \beta = \underbrace{E(\mathbf{X}_i \mathbf{X}_i')^{-1}}_{\text{k-by-k matrix}} \underbrace{E(\mathbf{X}_i Y_i)}_{\text{k-by-1 vector}}
 \end{aligned} \tag{3}$$

- 其中一阶条件 $E[\mathbf{X}_i(Y_i - \mathbf{X}_i' \beta)] = E[\mathbf{X}_i e_i] = \mathbf{0}$, 即有 $E[X_{ij} e_i] = 0$.
- 此正交条件即为矩条件 (moment condition), 也可以认为是参数识别 (parameter identification) 条件。

- 考虑仅有常数项与单个解释变量的情形: $\mathbf{X}_i' = (1, X_i)$, 此时

$$Y_i = \alpha + \beta_1 X_i + e_i \tag{4}$$

$$\text{两边取期望: } E(Y_i) = \alpha + \beta_1 E(X_i) + E(e_i) \tag{5}$$

由一阶条件 $E(\mathbf{X}_i e_i) = 0$ 可知 $E(X_i e_i) = 0$ 且 $E(e_i) = 0$, 从而有

$$E(X_i Y_i) = \alpha E(X_i) + \beta_1 E(X_i^2) \tag{6}$$

联立 (5) 与 (6), 可得:

$$\begin{cases} \beta_1 = \frac{E(X_i Y_i) - E(X_i)E(Y_i)}{E(X_i^2) - E(X_i)^2} = \frac{Cov(Y_i, X_i)}{V(X_i)} \\ \alpha = E(Y_i) - \beta_1 E(X_i) \end{cases}$$

命题 1. 回归系数分解公式:

$$\beta_k = \frac{Cov(Y_i, \tilde{X}_{ik})}{V(\tilde{X}_{ik})}, \quad X_{ik} = \mathbf{X}_{i,-k}' \gamma + \tilde{X}_{ik}$$

其中 \tilde{X}_{ik} 是将第 k 个解释变量 X_{ik} 回归到其他所有解释变量 $\mathbf{X}_{i,-k}$ 得到的残差项。

证明. 根据回归方程 $Y_i = \alpha + \beta_1 X_{i1} + \dots + \beta_k X_{ik} + \dots + \beta_K X_{iK} + e_i$, 将 $\tilde{X}_{ik} = X_{ik} - \mathbf{X}_{i,-k}' \gamma$ 代入该回归方程可得:

$$Y_i = \beta_k (\mathbf{X}_{i,-k}' \gamma + \tilde{X}_{ik}) + \mathbf{X}_{i,-k}' \beta_{-k} + e_i$$

根据矩条件 $E(\mathbf{X}_{i,-k}\tilde{X}_{ik}) = 0$ 和 $E(\tilde{X}_{ik}) = 0$, 可知 $Cov(\mathbf{X}_{i,-k}, \tilde{X}_{ik}) = 0$, 从而有

$$Cov(Y_i, \tilde{X}_{ik}) = \beta_k V(\tilde{X}_{ik}) + Cov(e_i, \tilde{X}_{ik})$$

□

注 1. 假设变量 X_{ik} 为研究的核心解释变量, 当调整控制变量时, 回归系数符号可能会改变:

$$\begin{aligned}\beta_k &= \frac{Cov(Y_i, \tilde{X}_{ik})}{V(\tilde{X}_{ik})} \\ &= \frac{1}{V(\tilde{X}_{ik})} [Cov(Y_i, X_{ik}) - Cov(Y_i, \mathbf{X}'_{i,-k})\gamma]\end{aligned}$$

在实证研究中, 通常通过逐步添加重要控制变量的方式来佐证结果的稳健性。

1.2 线性回归模型的基本性质

- 线性回归是所有计量模型的基础形式, 以下定理展示了线性回归模型的优良性质。

定理 1. (*Regression Justification 1*) 线性条件期望函数定理。假设条件期望函数是线性函数, 则线性回归函数为总体样本的条件期望函数, 即 $E(Y_i|\mathbf{X}_i) = \mathbf{X}'_i\beta$ 。

证明. 假设 $E(Y_i | \mathbf{X}_i) = \mathbf{X}'_i\beta^*$, 根据 CEF 正交分解定理, 有 $E[\mathbf{X}_i(Y_i - E(Y_i | \mathbf{X}_i))] = 0$, 从而 $E[\mathbf{X}_i(Y_i - \mathbf{X}'_i\beta^*)] = 0$, β^* 取值满足 $\beta^* = E(\mathbf{X}_i\mathbf{X}'_i)^{-1}E(\mathbf{X}_iY_i) = \beta$ 。 □

注 2. 该定理说明当总体样本的条件期望函数为线性函数时, 线性回归的系数与总体样本系数一致。

定理 2. (*Regression Justification 2*) 最优线性预测定理。对于所有关于 \mathbf{X}_i 的线性方程:

- (i) 线性回归函数 $\mathbf{X}'_i\beta$ 是 Y_i 的最佳线性预测量;
- (ii) $\mathbf{X}'_i\beta$ 是具有最小均方误差 (MSE) 的条件期望函数 $E(Y_i|\mathbf{X}_i)$ 的线性逼近函数。

证明. (i) $\beta = E(\mathbf{X}_i\mathbf{X}'_i)^{-1}E(\mathbf{X}_iY_i)$ 是最小化问题 $E[(Y_i - \mathbf{X}'_i\beta)^2]$ 的解;

(ii) 需要证明 $\beta = \underset{b}{\operatorname{argmin}} E[(E(Y_i | \mathbf{X}_i) - \mathbf{X}'_ib)^2]$, 注意到

$$\begin{aligned}(Y_i - \mathbf{X}'_ib)^2 &= [(Y_i - E(Y_i | \mathbf{X}_i)) + (E(Y_i | \mathbf{X}_i) - \mathbf{X}'_ib)]^2 \\ &= [Y_i - E(Y_i | \mathbf{X}_i)]^2 + [E(Y_i | \mathbf{X}_i) - \mathbf{X}'_ib]^2 + 2[Y_i - E(Y_i | \mathbf{X}_i)][E(Y_i | \mathbf{X}_i) - \mathbf{X}'_ib]\end{aligned}$$

对上式取期望，有

$$E[(Y_i - \mathbf{X}_i' b)^2] = E[Y_i - E(Y_i | \mathbf{X}_i)]^2 + E[(E(Y_i | \mathbf{X}_i) - \mathbf{X}_i' b)^2] + 2E[(E(Y_i | \mathbf{X}_i) - \mathbf{X}_i' b) \varepsilon_i]$$

根据 CEF 正交分解定理，有 $E[(E(Y_i | \mathbf{X}_i) - \mathbf{X}_i' b) \varepsilon_i] = 0$ ，即有

$$\beta = \operatorname{argmin}_b E[(Y_i - \mathbf{X}_i' b)^2] = \operatorname{argmin}_b E[(E(Y_i | \mathbf{X}_i) - \mathbf{X}_i' b)^2]$$

□

注 3. 即使总体的条件期望函数是非线性的，回归函数提供了 CEF 的最佳线性逼近！

- **分组回归：**线性回归中的系数可以理解为 $E(Y_i | \mathbf{X}_i)$ 关于 \mathbf{X}_i 的回归

$$\begin{aligned} \beta &= E(\mathbf{X}_i \mathbf{X}_i')^{-1} E(\mathbf{X}_i Y_i) \\ &= E(\mathbf{X}_i \mathbf{X}_i')^{-1} E[\mathbf{X}_i E(Y_i | \mathbf{X}_i)] \end{aligned}$$

- 比如 \mathbf{X}_i 是 i 的性别、出生地，没有 Y_i 的直接信息，但可以计算 $E(Y_i | \mathbf{X}_i)$ 分组的平均值
- 当 \mathbf{X}_i 是离散的时候，

$$E[(E(Y_i | \mathbf{X}_i) - \mathbf{X}_i' b)^2] = \sum [E(Y_i | \mathbf{X}_i = \mathbf{u}) - \mathbf{u}' b]^2 g_x(\mathbf{u})$$

其中 $g_x(\mathbf{u})$ 为概率密度函数

1.3 线性回归的统计推断

- 在现实情况，CEF 和 β 均不知道，但频数学派 (Frequentist) 认为 β 真实值是确定的，但基于随机变量的估计量本身具有随机性。
- 统计推断 (statistical inference) 用来刻画估计量的概率分布性质

$$\beta = E(X_i X_i')^{-1} E(X_i Y_i) \xrightarrow{\text{Sample Analog}} \hat{\beta} = \left(\sum_i X_i X_i' \right)^{-1} \sum_i X_i Y_i$$

- 样本假设： $W_i = (\mathbf{X}_i, Y_i)$ i.i.d
- 样本类比：
$$\begin{cases} E[W_i] = \frac{1}{N} \sum_{i=1}^N W_i \\ E[W_i W_i'] = \frac{1}{N} \sum_{i=1}^N W_i W_i' \end{cases}$$
- 该独立同分布假定保证了大数定律和中心极限定理的适用性

定理 3. 大数定律 (*Law of Large Numbers*) : 若随机变量 $\{X_i\}_{i=1}^N$ *i.i.d.*, 则有 $\bar{X} = \frac{1}{N} \sum_i X_i$ 依概率收敛于 $E(X_i)$, 即 $\text{plim} \bar{X} = E(X_i)$.

定理 4. 中心极限定理 (*Central Limit Theorem*) : 若随机变量 $\{X_i\}_{i=1}^N$ 分布满足 *i.i.d.* 且均值和方差分别为 μ 和 σ^2 , 则有

$$\sqrt{N}(\bar{X} - \mu) \xrightarrow{d} \mathcal{N}(\mu, \sigma^2)$$

定理 5. *Slutsky* 定理: $a_n \xrightarrow{d} F(\cdot)$, $\text{plim} b_n = b$ 则 $a_n + b_n \xrightarrow{d} a_n + b$, $a_n b_n \xrightarrow{d} a_n b$.

- OLS 系数估计量 $\hat{\beta}$ 的渐进分布:

$$\begin{aligned} \hat{\beta} &= \left(\sum_i \mathbf{X}_i \mathbf{X}_i' \right)^{-1} \sum_i \mathbf{X}_i Y_i \\ &= \left(\sum_i \mathbf{X}_i \mathbf{X}_i' \right)^{-1} \sum_i \mathbf{X}_i (\mathbf{X}_i' \beta + e_i) \\ &= \beta + \left(\sum_i \mathbf{X}_i \mathbf{X}_i' \right)^{-1} \sum_i \mathbf{X}_i e_i \\ \Rightarrow \quad \sqrt{N}(\hat{\beta} - \beta) &= \left(\frac{1}{N} \sum_i \mathbf{X}_i \mathbf{X}_i' \right)^{-1} \frac{1}{\sqrt{N}} \sum_i \mathbf{X}_i e_i \end{aligned}$$

- 经典误差独立假设要求 $E(e_i | \mathbf{X}_i) = 0$ or $E(e_i) = 0 \Rightarrow$ 无偏估计量 $E(\hat{\beta}) = \beta$
- By LLN, $\text{plim} \frac{1}{N} \sum_i \mathbf{X}_i \mathbf{X}_i' = E(\mathbf{X}_i \mathbf{X}_i')$;
- By CLT: $\frac{1}{\sqrt{N}} \sum_i \mathbf{X}_i e_i \xrightarrow{d} N(0, E(\mathbf{X}_i \mathbf{X}_i' e_i^2))$
- 运用 Slutsky 定理有

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}(0, E(\mathbf{X}_i \mathbf{X}_i')^{-1} E(\mathbf{X}_i \mathbf{X}_i' e_i^2) E(\mathbf{X}_i \mathbf{X}_i')^{-1}) \quad (7)$$

注 4. 对于随机变量 X 和 $a \in \mathbb{R}$, 有 $V(aX) = a^2 V(X)$. $V(Ax) = AE(XX')A$ 对于矩阵 $\mathbf{A} \in \mathbb{R}^{K \times K}$ 和随机向量 \mathbf{X} , 有

$$\begin{aligned} V(\mathbf{A}\mathbf{X}) &= E[(\mathbf{A}\mathbf{X} - E(\mathbf{A}\mathbf{X}))(\mathbf{A}\mathbf{X} - E(\mathbf{A}\mathbf{X}))'] \\ &= E[\mathbf{A}(\mathbf{X} - E(\mathbf{X}))(\mathbf{X}' - E(\mathbf{X}'))\mathbf{A}'] \\ &= \mathbf{A}E[(\mathbf{X} - E(\mathbf{X}))(\mathbf{X}' - E(\mathbf{X}'))]\mathbf{A}' \\ &= \mathbf{A}V(\mathbf{X})\mathbf{A}' \end{aligned}$$

- 可以使用样本类比得到估计此渐进分布的方差估计量为:

$$\left(\frac{1}{N} \sum_i \mathbf{X}_i \mathbf{X}_i' \right)^{-1} \left(\frac{1}{N} \sum_i \mathbf{X}_i \mathbf{X}_i' \hat{e}_i^2 \right) \left(\frac{1}{N} \sum_i \mathbf{X}_i \mathbf{X}_i' \right)^{-1}$$

其中残差项 $\hat{e}_i = Y_i - \mathbf{X}_i' \hat{\beta}$.

- 异方差稳健的标准误 (White, 1980)

- 在同方差假设条件下: $E(e_i^2 | \mathbf{X}_i) = \sigma^2$, 则有 $E(\mathbf{X}_i \mathbf{X}_i' e_i^2) = E(\mathbf{X}_i \mathbf{X}_i' E(e_i^2 | \mathbf{X}_i)) = \sigma^2 E(\mathbf{X}_i \mathbf{X}_i')$, 此时系数估计量渐进分布的方差为:

$$\begin{aligned} V \left[\sqrt{N}(\hat{\beta} - \beta) \right] &= E(\mathbf{X}_i \mathbf{X}_i')^{-1} E(\mathbf{X}_i \mathbf{X}_i' e_i^2) E(\mathbf{X}_i \mathbf{X}_i')^{-1} \\ &= E(\mathbf{X}_i \mathbf{X}_i')^{-1} \sigma^2 \end{aligned}$$

- 当用线性模型来近似 CEF 时:

$$\begin{aligned} E[(Y_i - \mathbf{X}_i' \beta)^2 | \mathbf{X}_i] &= E \{ [(Y_i - E(Y_i | \mathbf{X}_i)) + (E(Y_i | \mathbf{X}_i) - \mathbf{X}_i' \beta)]^2 | \mathbf{X}_i \} \\ &= V(Y_i | \mathbf{X}_i) + [E(Y_i | \mathbf{X}_i) - \mathbf{X}_i' \beta]^2 \end{aligned}$$

即使 $V(Y_i | \mathbf{X}_i)$ 是常数, 但是均方误差会随着回归线与 CEF 的偏离加大而增加。

- 尽管在理论上容易说明, 但异方差问题是一个实证问题: 异方差对标准误的影响没有确定的规律。在 Mostly Harmless Econometrics 中, 作者建议如果异方差标准误与同方差标准误相差超过 30% 以上, 则表示可能是有限样本导致的标准误计算误差。

1.4 线性回归的因果含义

- 实证问题: 受教育年限与收入水平的因果关系

- 如果没有读高中/本科/硕士/博士, 收入水平多高?
- 辍学决策: “The Road Not Taken” by Robert Frost

- 二元教育决策变量下的因果分析:

- $C_i \in \{0, 1\}$
- 潜在结果:

$$\text{潜在收入结果} = \begin{cases} Y_i^1 & \text{if } C_i = 1 \\ Y_i^0 & \text{if } C_i = 0 \end{cases}$$

- 根据之前的分析有:

$$\begin{aligned} \underbrace{E[Y_i | C_i = 1] - E[Y_i | C_i = 0]}_{\text{Observed difference in earnings}} &= \underbrace{E[Y_i^1 - Y_i^0 | C_i = 1]}_{\text{Average treatment effect on the treated}} \\ &\quad + \underbrace{E[Y_i^1 | C_i = 1] - E[Y_i^0 | C_i = 0]}_{\text{Selection bias}} \end{aligned} \quad (8)$$

注 5. 如果存在选择性偏误, $E[Y_i^1|C_i = 1] - E[Y_i^0|C_i = 0] > 0$, 教育对收入的影响会被高估。

- 条件独立假定 (Conditional Independence Assumption, CIA): 给定可以观测的特征 \mathbf{X}_i , 没有选择性偏误:

$$\{Y_i^1, Y_i^0\} \perp C_i | \mathbf{X}_i$$

换言之, $E[Y_i|\mathbf{X}_i, C_i = 1] - E[Y_i|\mathbf{X}_i, C_i = 0] = E[Y_i^1 - Y_i^0|\mathbf{X}_i]$.

注 6. 在 CIA 下, 可以得到平均处理效应 (ATE)。若只需要得到 ATT, 只需要假定 $Y_i^1 \perp C_i | \mathbf{X}_i$ 或者 $Y_i^0 \perp C_i | \mathbf{X}_i$ 。

- 多元取值教育变量下的因果分析:

- 假设个体收入满足方程: $Y_i^s = f_i(s)$, 该方程刻画了不同 s 取值情况下的收入水平;
- 实际观测的个体收入水平为:

$$Y_i = \sum_{s \in \mathcal{S}} \mathbb{I}(s_i = s) Y_i^s$$

- CIA: $Y_i^s \perp s_i | \mathbf{X}_i, \forall s$, 即给定 \mathbf{X}_i , s_i 是随机分配的, 可以认为 s_i 的决策方程如下:

$$s_i = g(\mathbf{X}_i) + \epsilon_i$$

其中 $Y_i^s \perp \epsilon_i | \mathbf{X}_i$ 。

- 特征 \mathbf{X}_i 处的平均因果效应:

- * k 年教育经历对收入的因果影响为: $E[f_i(s) - f_i(s-4)|\mathbf{X}_i]$
- * 但是对于任意个体 i , 只能观测到 $f_i(s = s_i)$, 即其实际接受教育年限和收入水平
- * 在 CIA 假定下有:

$$\begin{aligned} E[Y_i|\mathbf{X}_i, s_i = s] - E[Y_i|\mathbf{X}_i, s_i = s-1] \\ = E[f_i(s) - f_i(s-1)|\mathbf{X}_i] \end{aligned}$$

注 7. 比如要研究高中毕业的收入效应, 根据 CIA 可知:

$$\begin{aligned} E[f_i(12)|\mathbf{X}_i, s_i = 12] - E[f_i(11)|\mathbf{X}_i, s_i = 11] \\ = E[f_i(12) - f_i(11)|\mathbf{X}_i, s_i = 12] \\ = E[f_i(12) - f_i(11)|\mathbf{X}_i] \end{aligned}$$

此时, 根据 CIA, 给定可以观测的特征, 高中辍学决策跟潜在收入无关, 并且在 \mathbf{X}_i 处有 ATT 与 ATE 相等。

– 总体平均因果效应:

$$\begin{aligned} & E\{E[Y_i|\mathbf{X}_i, s_i = s] - E[Y_i|\mathbf{X}_i, s_i = s - 1]\} \\ &= E\{E[f_i(s) - f_i(s - 1)|\mathbf{X}_i]\} \\ &= E[f_i(s) - f_i(s - 1)] \end{aligned}$$

– 分样本平均因果效应:

$$E[f_i(s) - f_i(s - 1)|s_i = s]$$

注 8. 如果要研究本科教育的平均因果效应, $E[f_i(16) - f_i(12)|s_i = 16]$ 表示接受本科教育对于本科生收入的平均效应, 而 $E[f_i(16) - f_i(12)]$ 表总体平均效应。

注 9. 总体平均因果效应可以通过如下计算式得到

$$E[f_i(s) - f_i(s - 1)] = \int E[f_i(s) - f_i(s - 1)|\mathbf{X}_i = x]dF_{\mathbf{X}}(x)$$

即为关于 \mathbf{X}_i 概率密度函数的加权平均。

注 10. 因果效应的计算过程实质上是一个基于个体特征变量 \mathbf{X}_i 的匹配估计量 (Matching Estimator):

- (1) 对于任意 \mathbf{X}_i 取值, 比较具有“相同”特征的处理组 (如 $s_i = s$) 和对照组 (如 $s_i = s - 1$)
- (2) 根据 \mathbf{X}_i 概率密度函数进行加权平均

- 因果效应的线性模型

– 假设个体收入方程具有如下形式:

$$f_i(s) = \alpha + \rho s + \eta_i, \quad s \in \mathcal{S} \quad (9)$$

* 该模型刻画了不同教育年限 s 下的潜在收入水平。

– 将数据 (s_i, Y_i) 代入上述模型可得:

$$Y_i = \alpha + \rho s_i + \underbrace{\mathbf{X}_i' \boldsymbol{\gamma} + \nu_i}_{\equiv \eta_i} \quad (10)$$

– s_i 可能通过个体特征 \mathbf{X}_i 与 η_i 相关

* 基于可观测变量的选择假设 (Selection-on-observables Assumption): $E[\eta_i|\mathbf{X}_i] = \mathbf{X}_i' \boldsymbol{\gamma} \Leftrightarrow E[v_i|\mathbf{X}_i] = 0$ 利用 CIA 可得:

$$\begin{aligned} E[f_i(s)|\mathbf{X}_i, s_i] &= E[f_i(s)|\mathbf{X}_i] \\ &= \alpha + \rho s + \mathbf{X}_i' \boldsymbol{\gamma} \end{aligned}$$

这说明模型 (10) 满足如下线性无关假定：

$$E[Y_i | \mathbf{X}_i, s_i] = \alpha + \rho s_i + \mathbf{X}_i' \boldsymbol{\gamma} \quad (11)$$

注 11. **教育投资结构模型**：考虑个体 i 的教育决策问题：

$$\max_s \{f_i(s) - C_i(s; \mathbf{X}_i)\}$$

其中 $C_i(s; \mathbf{X}_i)$ 为接受教育的成本。从而最优的教育决策为

$$f'_i(s^*) = C'_i(s^*; \mathbf{X}_i) \Rightarrow s^* = g(\mathbf{X}_i)$$

添加个体扰动之后，个体最优教育投资决策方程为：

$$s_i = s^* + u_i = g(\mathbf{X}_i) + u_i$$

CIA 假定要求：

$$Y_i^s \perp u_i | \mathbf{X}_i$$